

Computer Vision: Machine Learning based Facial Recognition, Autonomous Driving, and Image Processing

TA: Shujian Yu


Date: 2026/04/25

- 目标检测基本流程与难点
- 模板匹配与归一化互相关
- Haar特征、积分图与Viola-Jones算法
- 提升（AdaBoost）及级联分类器结构
- HoG特征与SVM检测
- 工程特征与数据驱动方法对比
- Mixture of Experts模型
- 发展趋势与总结

目标检测 (Object Detection) 的任务是找出图像中所有感兴趣的目标 (物体), 确定它们的类别和位置, 是计算机视觉领域的核心问题之一。由于各类物体有不同的外观、形状和姿态, 加上成像时光照、遮挡等因素的干扰, 目标检测一直是计算机视觉领域最具有挑战性的问题。

计算机视觉中关于图像识别有四大类任务:

- (1) 分类-Classification: 解决“是什么?”的问题, 即给定一张图片或一段视频判断里面包含什么类别的目标。
- (2) 定位-Location: 解决“在哪里?”的问题, 即定位出这个目标的位置。
- (3) 检测-Detection: 解决“在哪里? 是什么?”的问题, 即定位出这个目标的位置并且知道目标物是什么。
- (4) 分割-Segmentation: 分为实例的分割 (Instance-level) 和场景分割 (Scene-level), 解决“每一个像素属于哪个目标物或场景”的问题。



- 目标检测的定义：在图片中定位并分类目标
- 常见应用领域：人脸检测、行人检测、自动驾驶等
- 目标检测的核心挑战：
 - 多尺度、姿态变化
 - 部分遮挡
 - 背景杂波
 - 假阳性/假阴性

1) 人脸检测

- 智能门控
- 员工考勤签到
- 智慧超市
- 人脸支付
- 车站、机场实名认证
- 公共安全:逃犯抓捕、走失人员检测

2) 行人检测

- 智能辅助驾驶
- 智能监控
- 暴恐检测(根据面相识别暴恐倾向)
- 移动侦测、区域入侵检测、安全帽/安全带检测

3) 车辆检测

- 自动驾驶
- 违章查询、关键通道检测
- 广告检测(检测广告中的车辆类型,弹出链接)

4) 遥感检测


- 大地遥感,如土地使用、公路、水渠、河流监控
- 农作物监控
- 军事检测

传统的目标检测方法：

- 首先需要提供待检测图片
- 然后将**滑动窗口（Sliding Windows）和图像金字塔（Image Pyramid）**这两种方法相结合。
- 从图片中选择出一些区域。
- 通过一些算法提取出这些区域的特征信息。
- 然后通过机器学习的分类器对提取的特征分类。
- 目标检测的输出结果一般是使用矩形框标记出要检测的目标。
- 但是使用滑动窗口和图像金字塔时在同一个目标上会标记出多个矩形框。
- 所以我们需要使用非极大值抑制（Non-maxima suppression）来剔除多余的矩形框。

滑动窗口（Sliding Windows）在目标检测过程中的作用

- 定位目标（物体、动物等）在图片中的位置。
 - 1) 在计算机视觉中滑动窗口是一个矩形框。
 - 2) 它沿着从左向右、从上向下的方向在图片上滑动，以达到提取出图片中每一个区域的目的。



最早的目标检测思路就是滑窗法，虽然简单直接，但面对大图和多尺度目标时，计算负担极大。因此后续各种方法都围绕“高效性”展开改进。


滑窗法类似穷举进行图像子区域搜索,但是一般情况下图像中大部分子区域是没有物体的。学者们自然而然想到只对图像中最有可能包含物体的区域进行搜索以此来提高计算效率。

选择搜索(selective search,简称SS)方法是当下最为熟知的图像bounding boxes提取算法,由Koen E.A于2011年提出。选择搜索算法的主要思想:图像中物体可能存在的区域应该是有某些相似性或者连续性区域的。因此,选择搜索基于上面这一想法采用子区域合并的方法进行提取bounding boxes。

首先,对输入图像进行分割算法产生许多小的子区域。然后,根据这些子区域之间相似性(相似性标准主要有颜色、纹理、大小等等)进行区域合并,不断的进行区域迭代合并。每次迭代过程中对这些合并的子区域做bounding boxes(外切矩形),这些子区域外切矩形就是通常所说的候选框。



在过去的二十年里，目标检测技术经历了两个重要的历史阶段：传统目标检测时期（2014年之前）和基于深度学习的检测时期（2014年之后）。




目前，基于深度学习的方法是目标检测领域的主流解决方式，它通常分为两类：

- **两阶段（Two-stage）检测方法：**这种方法先从图像中提取出潜在的对象候选区域，然后对这些区域进行详细的分类和边界框精调。代表模型包括R-CNN系列（如Fast R-CNN, Faster R-CNN）和基于区域的全卷积网络（如Mask R-CNN）。
- **单阶段（One-stage）检测方法：**这种方法直接在图像上预测对象的类别和位置，速度通常更快，但在准确度上可能略逊于两阶段方法。代表模型包括YOLO（You Only Look Once）、SSD（Single Shot MultiBox Detector）和RetinaNet等。

两阶段 (Two-stage)

- RCNN: 利用选择性搜索生成区域提议, 然后将这些区域的特征通过CNN提取, 并使用SVM分类。
- Fast RCNN: 改进了RCNN的流程, 通过共享卷积特征图来提高速度, 并且在同一个网络中同时训练分类器和边界框回归器。
- Faster RCNN: 引入RPN来端到端地生成区域提议, 显著提高了生成提议的速度和效率。
- FPN (Feature Pyramid Networks): 通过一个自顶向下的结构和横向连接, 为不同尺度的对象构建了高层次的语义特征, 以改善多尺度目标的检测性能。




单阶段（One-stage）


YOLO（You Only Look Once）是继RCNN，fast-RCNN和faster-RCNN之后，Ross Girshick针对DL目标检测速度问题提出的另一种框架，其核心思想是生成RoI+目标检测两阶段（two-stage）算法用一套网络的一阶段（one-stage）算法替代，直接在输出层回归bounding box的位置和所属类别。

之前的物体检测方法首先需要产生大量可能包含待检测物体的先验框，然后用分类器判断每个先验框对应的边界框里是否包含待检测物体，以及物体所属类别的概率或者置信度，同时需要后处理修正边界框，最后基于一些准则过滤掉置信度不高和重叠度较高的边界框，进而得到检测结果。这种基于先产生候选区再检测的方法虽然有相对较高的检测准确率，但运行速度较慢。

YOLO创造性的将物体检测任务直接当作回归问题（regression problem）来处理，将候选区和检测两个阶段合二为一。只需一眼就能知道每张图像中有哪些物体以及物体的位置。下图展示了各物体检测系统的流程图。



YOLOv1网络有24个卷积层，后面是2个全连接层。我们只使用 1×1 降维层，后面是 3×3 卷积层。如下图所示：



为了快速实现快速目标检测，YOLOV1还训练了快速版本。快速YOLO使用具有较少卷积层（9层而不是24层）的神经网络，在这些层中使用较少的滤波器。除了网络规模之外，YOLO和快速YOLO的所有训练和测试参数都是相同的。网络的最终输出是 $7*7*30(1470)$ 的预测张量。

<https://github.com/ultralytics/ultralytics>

- 传统检测方法的贡献：
 - 提供了高效、可解释的目标检测思路
 - 至今仍用于嵌入式、低算力场景
- 深度学习的变革：
 - 从特征到分类端到端自动化
 - 大幅提升检测准确率与适应性
- 未来方向：
 - 融合多模态信息
 - 轻量级模型与实时检测
 - 更强的跨域泛化能力

Computer Vision: Machine Learning based Facial Recognition, Autonomous Driving, and Image Processing

TA: Shujian Yu

Date: 2026/04/25