


Computer Vision: Machine Learning based Facial Recognition, Autonomous Driving, and Image Processing

TA: Shujian Yu

Date: 2026/05/02


--传统方法：级联分类器 (Viola-Jones)

- 核心思想：分层过滤、快速排除
- 关键指标：级联FP率计算
- 应用场景：实时人脸检测




--深度学习初期：R-CNN系列

- R-CNN：区域建议+CNN特征提取
- Fast R-CNN：ROI Pooling加速
- Faster R-CNN：RPN网络端到端训练




--实时检测突破：YOLO系列

- 设计哲学：回归式单次检测
- 核心创新：网格化预测、统一损失函数



方法	检测流程	速度(FPS)	mAP	优缺点
级联分类器	滑动窗口+特征筛选	15-100	20-30	快但精度低
R-CNN	区域建议+CNN+SVM	0.1	53.3	精度高但速度极慢
Fast R-CNN	ROI Pooling+多任务损失	0.5	70.0	速度提升但依赖外部建议
YOLO v1	单次回归全局预测	45	63.4	实时但小目标检测差




VGG16是一种深度卷积神经网络模型，用于图像分类和识别任务。它是由牛津大学的研究团队开发的，命名为Visual Geometry Group (VGG)，并在2014年的ImageNet图像识别挑战中取得了很好的成绩。

VGG16模型具有13个卷积层和3个全连接层，总共有约138百万个可训练参数。该模型的核心思想是通过堆叠多个小尺寸的卷积核和池化层来增加网络的深度，从而提高图像特征的代表能力。它采用了相对较小的3x3卷积核和2x2最大池化核，每个卷积层后都使用了ReLU激活函数。


VGG16的结构相对简单而经典，是深度学习中常用的基准模型之一。它在图像分类任务中表现出色，能够有效地识别和区分不同的物体类别。由于其简单的结构和可扩展性，VGG16也常被用作迁移学习的基础模型，在各种计算机视觉任务中发挥重要作用，如目标检测、图像分割等。

- 输入图像尺寸为 $224 \times 224 \times 3$ ，经64个通道为3的 3×3 的卷积核，步长为1，padding=same填充，卷积两次，再经ReLU激活，输出的尺寸大小为 $224 \times 224 \times 64$
- 经max pooling（最大化池化），滤波器为 2×2 ，步长为2，图像尺寸减半，池化后的尺寸变为 $112 \times 112 \times 64$
- 经128个 3×3 的卷积核，两次卷积，ReLU激活，尺寸变为 $112 \times 112 \times 128$
- max pooling池化，尺寸变为 $56 \times 56 \times 128$
- 经256个 3×3 的卷积核，三次卷积，ReLU激活，尺寸变为 $56 \times 56 \times 256$
- max pooling池化，尺寸变为 $28 \times 28 \times 256$
- 经512个 3×3 的卷积核，三次卷积，ReLU激活，尺寸变为 $28 \times 28 \times 512$
- max pooling池化，尺寸变为 $14 \times 14 \times 512$
- 经512个 3×3 的卷积核，三次卷积，ReLU，尺寸变为 $14 \times 14 \times 512$
- max pooling池化，尺寸变为 $7 \times 7 \times 512$
- 然后Flatten()，将数据拉平成向量，变成一维 $512 \times 7 \times 7 = 25088$ 。再经过两层 $1 \times 1 \times 4096$ ，一层 $1 \times 1 \times 1000$ 的全连接层（共三层），经ReLU激活
- 最后通过softmax输出1000个预测结果

采用多个卷积层，用较小的卷积核代替具有卷积核的较大卷积层，一方面可以减少参数，而且作者认为它等价于更多的非线性映射，提高了拟合的表达能力。



https://blog.csdn.net/u012661539/article/details/131326597?ops_request_misc=%257B%2522request%255Fid%2522%253A%25227212ad22135d1153c5ed1a254a575ddc%2522%252C%2522scm%2522%253A%252220140713.130102334..%2522%257D&request_id=7212ad22135d1153c5ed1a254a575ddc&biz_id=0&utm_medium=distribute.pc_search_result.none-task-blog-2~all~top_positive~default-1-131326597-null-null.142^v102^pc_search_result_base4&utm_term=vgg16%E6%A8%A1%E5%9E%8B&spm=1018.2226.3001.4187



https://blog.csdn.net/knighthood2001/article/details/138075554?ops_request_misc=%257B%2522request%255Fid%2522%253A%2522f619bbc33d70198cab834e59b6be9e07%2522%252C%2522scm%2522%253A%252220140713.130102334..%2522%257D&request_id=f619bbc33d70198cab834e59b6be9e07&biz_id=0&utm_medium=distribute.pc_search_result.none-task-blog-2~all~top_positive~default-1-138075554-null-null.142^v102^pc_search_result_base4&utm_term=unet&spm=1018.2226.3001.4187

- UNet算法是一种用于图像分割的卷积神经网络（Convolutional Neural Network，简称CNN）架构。它由Olaf Ronneberger等人在2015年提出，主要用于解决医学图像分割的问题。
- UNet算法的特点是采用了U型的网络结构，因此得名UNet。
- 该网络结构具有编码器（Encoder）和解码器（Decoder）两个部分。
 - 编码器负责逐步提取输入图像的特征并降低空间分辨率。
 - 解码器则通过上采样操作将特征图恢复到原始输入图像的尺寸，并逐步生成分割结果。
- UNet算法的关键创新是在解码器中引入了跳跃连接（Skip Connections），即将编码器中的特征图与解码器中对应的特征图进行连接。这种跳跃连接可以帮助解码器更好地利用不同层次的特征信息，从而提高图像分割的准确性和细节保留能力。
- UNet算法在医学图像分割领域表现出色，特别适用于小样本、不平衡数据和需要保留细节信息的任务。它已被广泛应用于肿瘤分割、器官分割、细胞分割等领域，并成为图像分割领域的重要算法之一。

优点：

- 强大的分割能力：UNet算法采用了U型的网络结构和跳跃连接机制，能够有效地捕获不同层次的特征信息，从而提高图像分割的准确性和细节保留能力。
- 少样本学习：相比其他深度学习方法，UNet算法对于小样本情况表现出色，可以在较少的标注数据上进行训练，并取得较好的分割效果。
- 可扩展性：UNet算法的网络结构简单明了，容易进行扩展和修改。可以根据具体任务的需求进行网络结构的调整，添加或删除网络层次。

缺点：

- 计算资源需求较高：由于UNet算法通常需要处理较大的图像输入和较深的网络结构，因此对计算资源的要求较高，包括显存和计算能力。
- 数据不平衡问题：如果训练数据中存在类别不平衡的情况，UNet算法可能会倾向于预测出现频率较高的类别，而忽略出现频率较低的类别。这需要在数据预处理或损失函数设计上进行相应的处理。
- 对于大尺寸图像的处理：由于UNet算法的网络结构和内存限制，对于大尺寸的图像，需要进行分块处理或采用其他策略来解决内存不足的问题。

Computer Vision: Machine Learning based Facial Recognition, Autonomous Driving, and Image Processing

TA: Shujian Yu

Date: 2026/05/02