

Computer Vision: Machine Learning based Facial Recognition, Autonomous Driving, and Image Processing

TA: Shujian Yu

Date: 2026/05/10

- 视觉运动分析：介绍了光流（Optical Flow）的基本概念及其在计算机视觉中的应用。
- 光流算法：重点讲解了两种经典光流估计算法——Horn-Schunck（全局、平滑约束）和Lucas-Kanade（局部、分块常量假设），包括它们的原理、假设及求解方法。
- 特征点检测：讲解了Harris角点检测器、SIFT和SURF等特征提取与匹配方法，分析了算法的旋转、尺度不变性以及它们在图像配准、目标检测中的应用。
- 运动分析方法：介绍了MOSES等框架在视频运动提取和分析中的应用。
- 稀疏与稠密光流：比较了稀疏光流和稠密光流的不同应用场景。
- 实际应用：讨论了上述方法在医学图像（如上皮细胞交互）、动作识别等领域的实际应用和效果评估。

光流 (Optical Flow) 是指描述在图像序列中物体表面上的像素移动的模式。在计算机视觉和图像处理领域，光流是一种用于估计相邻帧之间像素之间位移的技术。

简而言之，光流是描述相邻图像帧之间像素运动的模式，它通过跟踪图像中的特征点或像素来估计运动的速度和方向。或者说是在像素级别上的位移描述，即每一个像素点从第一帧到第二帧的具体偏移量。



运动检测与目标跟踪（如视频监控、自动驾驶）；视频稳定（如手持相机的防抖功能）；动作识别（如人体姿态估计）；3D 结构重建（如基于单目视频的深度估计）；机器人视觉（如 SLAM 和路径规划）。

光流的计算基于两个核心假设：

2.1 亮度恒常性假设 (Brightness Constancy Assumption, BCA)

在短时间内，移动的物体点在图像中的亮度不变：

$$I(x, y, t) = I(x + \Delta x, y + \Delta y, t + \Delta t)$$

其中：

$I(x, y, t)$ 是图像上点 (x, y) 处在时间 t 时的像素强度（灰度值）。 $(x + \Delta x, y + \Delta y)$ 是该点在下一帧中的位置。

2.2 小运动假设 (Small Motion Assumption)

假设物体的运动幅度较小，可以对亮度变化进行泰勒展开：

$$I(x + \Delta x, y + \Delta y, t + \Delta t) \approx I(x, y, t) + \frac{\partial I}{\partial x} \Delta x + \frac{\partial I}{\partial y} \Delta y + \frac{\partial I}{\partial t} \Delta t$$


根据亮度恒常性：

$$\frac{\partial I}{\partial x} \Delta x + \frac{\partial I}{\partial y} \Delta y + \frac{\partial I}{\partial t} \Delta t = 0$$


替换后得到 光流约束方程 (Optical Flow Constraint Equation, OFCE)：

$$I_x u + I_y v + I_t = 0$$


- Lucas-Kanade 方法（局部方法）--假设在一个小窗口内所有像素点的光流是相同的。
- Horn-Schunck 方法（全局方法）--采用全局平滑性假设，优化能量函数。
- FlowNet (2015) --采用 CNN 直接回归光流。
- PWC-Net (2018) --引入金字塔、Warping 和 Cost Volume，提升计算效率。
- RAFT (2020) --通过递归更新的 Cost Volume 和 GRU 迭代优化，实现高精度光流估计。



FlowNet




SPyNet




RAFT

FlowNet-S




FlowNetSimple是最简单粗暴的一种网络结构，该网络直接把输入的两帧图像在通维度上堆叠（拼接）在一起，然后使用一系列卷积层进行下采样提取特征，让网络自行决定如何处理图像对以从中提取运动信息，网络结构如上图所示。

FlowNet-C



FlowNet-C与FlowNet-S的区别在于，FlowNet-C首先对两个输入图像建立两个独立但相同的处理流，通过一系列的卷积层分别提取两个图像的有意义的特征表示。随后在更高的层次上将这些有意义的特征表示组合到一起进行后续的下采样过程，网络结构如图上图所示。


但是两个图像高层特征的组合并不是简单的维度堆叠，而是采用了关联层来促进网络的匹配过程。我们知道，该网络的最终目的是预测两张图像之间的光流，而光流本质上就是一种不同图像之间的对应匹配关系，为了“帮助”网络加速计算这种匹配关系、提高网络性能、提高估计的准确性，我们引入了一个“correlation layer”来组合特征。“correlation”操作就是一种相关性计算，用以计算不同特征/图像块之间的相关性，结果指标用来反应其匹配程度大小，我们通过这种先行的匹配计算来组合高层特征，可以说为网络后续的匹配关系学习提供了强有力的指导。



在解码/扩展阶段（如上图所示），该阶段主要包括多次上采样操作，用以恢复图像尺寸和信息。为了更好地融合来自不同层的语义信息，每一层的输入除了上一层的输出外，还有利用上一层输出预测的“光流”和来自编码器对应层的特征。这样我们既保留了从较粗糙的特征图中传递的高级信息，又保留了较低层特征图中提供的精细局部信息。

每一次上采样增加两倍分辨率，重复4次该过程，得到一个预测输出流。注意其分辨率仍然比输入图像原尺寸小4倍，后续使用双线性插值恢复即可。因为文章发现，与全图像分辨率计算成本较低的双线性插值上采样相比，从该分辨率继续进行网络学习对结果并不会会有大的改善，所以可以直接双线性插值得到和输入相同分辨率的光流预测图。

FlowNet2.0



Computer Vision: Machine Learning based Facial Recognition, Autonomous Driving, and Image Processing

TA: Shujian Yu

Date: 2026/05/10