

Computer Vision: Machine Learning based Facial Recognition, Autonomous Driving, and Image Processing

TA: Shujian Yu

Date: 2026/05/24

- 背景

1. 计算机视觉任务需要捕捉长程依赖。
2. CNN 善于提取局部模式，但“感受野”有限。
3. RNN/LSTM 能处理序列，却串行计算、梯度传播困难。
4. 借鉴 NLP 的注意力机制，可并行建模任意距离的依赖关系。

- 递归网络回顾

1. RNN 通过隐藏状态递归更新来处理序列；参数在时间维共享。
2. 训练难点：梯度消失/爆炸。
3. LSTM 通过「输入门、遗忘门、输出门」在细胞状态中维持常量误差流，缓解长程记忆问题。


- 注意力机制与 Transformer

1. LSTM 结构限制并行；注意力允许模型直接对齐远距元素，计算可完全并行。


监督学习利用大量的标注数据来训练模型，模型的预测和数据的真实标签产生损失后进行反向传播（计算梯度、更新参数），通过不断的学习，最终可以获得识别新样本的能力。

无监督学习不依赖任何标签值，通过对数据内在特征的挖掘，找到样本间的关系，比如聚类相关的任务。

有监督和无监督最主要的区别在于模型在训练时是否需要人工标注的标签信息：



无监督学习中被广泛采用的方式是自动编码器（autoencoder）：




自监督学习主要是利用辅助任务 (pretext) 从大规模的无监督数据中挖掘自身的监督信息, 通过这种构造的监督信息对网络进行训练, 从而可以学习到对下游任务有价值的表征。(也就是说自监督学习的监督信息不是人工标注的, 而是算法在大规模无监督数据中自动构造监督信息, 来进行监督学习或训练。因此, 大多数时候, 我们称之为无监督预训练方法或无监督学习方法, 严格上讲, 他应该叫自监督学习)

对于自监督学习来说, 存在三个挑战:


- 对于大量的无标签数据, 如何进行表征/表示学习?
- 从数据的本身出发, 如何设计有效的辅助任务 pretext?
- 对于自监督学习到的表征, 如何来评测它的有效性?

Pretrain-Fintune 模式

Supervised Pipeline





Self-Supervised Pipeline




比如在 NLP 领域中最重要算法 Word2vec。Word2vec 主要是利用语句的顺序，例如 CBOW 通过前后的词来预测中间的词，而 Skip-Gram 通过中间的词来预测前后的词。

Word2Vec





而在图像任务中，研究人员通过一种名为 Jigsaw（拼图）的方式来构造辅助任务。我们可以将一张图分成 9 个部分，然后通过预测这几个部分的相对位置来产生损失。比如我们输入这张图中的小猫的眼睛和右耳朵，期待让模型学习到猫的右耳朵是在脸部的右上方的，如果模型能很好的完成这个任务，那么我们就可以认为模型学习到的表征是具有语义信息的。



后续人们又拓展了这种拼图的方式，设计了更加复杂的，或者说更难的任务。首先我们依然将图片分为 9 块，我们预先定义好 64 种排序方式。模型输入任意一种被打乱的序列，期待能够学习到这种序列的顺序属于哪个类(64分类)，和上个工作相比，这个模型需要学习到更多的相对位置信息。这个工作带来的启发就是使用更强的监督信息，或者说辅助任务越难，最后的性能越好。


自监督学习-基于时序(Temporal Based)

第一种思想是基于帧的相似性，对于视频中的每一帧，其实存在着特征相似的概念，简单来说我们可以认为视频中的相邻帧特征是相似的，而相隔较远的视频帧是不相似的，通过构建这种相似（positive）和不相似（negative）的样本来进行自监督约束。



另外，对于同一个物体的拍摄是可能存在多个视角（multi-view），对于多个视角中的同一帧，可以认为特征是相似的，对于不同帧可以认为是不相似的。

还有一种想法是来自 @Xiaolong Wang ICCV 2015 的基于无监督追踪方法，首先在大量的无标签视频中进行无监督追踪，获取大量的物体追踪框。那么对于一个物体追踪框在不同帧的特征应该是相似的（positive），而对于不同物体的追踪框中的特征应该是不相似的（negative）。



自监督学习-基于对比 (Contrastive Based)


第三类自监督学习的方法是基于对比约束，它通过学习对两个事物的相似或不相似进行编码来构建表征。我们第二部分所介绍的基于时序的方法已经涉及到了这种基于对比的约束，通过构建正样本 (positive) 和负样本 (negative)，然后度量正负样本的距离来实现自监督学习。核心思想样本和正样本之间的距离远远大于样本和负样本之间的距离：

$$\text{score}(f(x), f(x^+)) \gg \text{score}(f(x), f(x^-))$$

这里的 x 通常也称为「anchor」数据，为了优化 anchor 数据和其正负样本的关系，我们可以使用点积的方式构造距离函数，然后构造一个 softmax 分类器，以正确分类正样本和负样本。这应该鼓励相似性度量函数（点积）将较大的值分配给正例，将较小的值分配给负例：

$$\mathcal{L}_N = -\mathbb{E}_X \left[\log \frac{\exp(f(x)^T f(x^+))}{\exp(f(x)^T f(x^+)) + \sum_{j=1}^{N-1} \exp(f(x)^T f(x_j))} \right]$$

通常这个损失也被称为 InfoNCE，后面的所有工作也基本是围绕这个损失进行的。



<https://github.com/jason718/awesome-self-supervised-learning>

Self-attention & Transformers


In the [previous post, we looked at Attention](#) – a ubiquitous method in modern deep learning models. Attention is a concept that helped improve the performance of neural machine translation applications. In this post, we will look at **The Transformer** – a model that uses attention to boost the speed with which these models can be trained. The Transformer outperforms the Google Neural Machine Translation model in specific tasks. The biggest benefit, however, comes from how The Transformer lends itself to parallelization. It is in fact Google Cloud's recommendation to use The Transformer as a reference model to use their [Cloud TPU](#) offering. So let's try to break the model apart and look at how it functions.

The Transformer was proposed in the paper [Attention is All You Need](#). A TensorFlow implementation of it is available as a part of the [Tensor2Tensor](#) package. Harvard's NLP group created a [guide annotating the paper with PyTorch implementation](#). In this post, we will attempt to oversimplify things a bit and introduce the concepts one by one to hopefully make it easier to understand to people without in-depth knowledge of the subject matter.

2025 Update: We've built a [free short course](#) that brings the contents of this post up-to-date with animations:



<https://jalammar.github.io/illustrated-transformer/>



Attention in transformers, step-by-step | DL6



3Blue1Brown
7.28M subscribers

Subscribe

65K



Share



Download



Thanks



2.6M views 1 year ago Neural networks

揭开注意力的神秘面纱，变压器和 LLM 内部的关键机制。

这些课程不是搜索广告阅读，而是由观众直接资助：<https://3b1b.co/support> 特...more

<https://www.youtube.com/watch?v=eMlx5fFNoYc>

<https://github.com/huggingface/transformers>

Review time!



Assignment: Counting puffins is an important conservation task. To assist human volunteers, you are being asked to develop an automated counting algorithm.

- (1) Motivate which approach or learning model you would propose to use.
(20 points)
- (2) Describe how you would collect a dataset for training, validation, and testing with concrete numbers. Provide detailed examples how type of annotations you would require.
(30 points)
- (3) Provide at least three example images on which you expect the algorithm to fail. Comment why you think the algorithm would fail to estimate the correct number of samples for a given image. These scenarios should cover different failure modes. Please include example image in your text.
(30 points)
- (4) Outline a short plan how you would deploy the algorithm. Volunteers will provide the images on their cell phones.
(20 point)

Computer Vision: Machine Learning based Facial Recognition, Autonomous Driving, and Image Processing

TA: Shujian Yu

Date: 2026/05/24